

IID 连续 Label Flip：RTC 与 FedAvg 60 轮实验分析

60 轮 IID 连续 Label Flip 的攻击效果、检测分离度、硬约束代价与可信度诊断。

技术摘要

六组结果均完整落盘，硬权重、影响预算、轮次和数据清单门禁全部通过。结论不是“RTC 对 Label Flip 普遍有效”：它对全标签反转很强，但对 5→3 定向翻转失效。

- **All-reverse：有效。** RTC 将主动期恶意权重从 20.20% 压到 0.08%，主动期准确率由 78.79% 提升到 83.96%；与 RTC 自身 clean 相比只损失 0.48 个百分点。
- **5→3 targeted：无效且略有负收益。** RTC 主动期 ASR 38.66%，高于 FedAvg 的 34.89%；ASR-AUC 18.86 对 16.93，恶化 11.4%。主动期准确率也低 1.91 个百分点。
- **Clean 代价存在。** RTC 第 60 轮准确率 88.91%，低于 FedAvg 的 90.06%；第 11–60 轮等长窗口平均低 1.56 个百分点。

当前实现可保留为高强度更新异常的安全边界，但还不能宣称对隐蔽定向 Label Flip 有效。

Source: 实验汇总与配对比较

Tables: logs\label_flip_continuous_iid\comparison_runs.csv, logs\label_flip_continuous_iid\rounds*.csv

RTC all-reverse 主动期准确率

84%

All-reverse 第 11–60 轮平均准确率。

FedAvg 78.8%

Source: 实验汇总与配对比较

Tables:
logs\label_flip_continuous_iid\comparison_runs.csv,
logs\label_flip_continuous_iid\rounds*.csv

RTC targeted ASR-AUC

18.86

5→3 第 11–60 轮 ASR 曲线梯形积分；越低越好。

FedAvg 16.93

Source: 实验汇总与配对比较

Tables:
logs\label_flip_continuous_iid\comparison_runs.csv,
logs\label_flip_continuous_iid\rounds*.csv

RTC clean 最终准确率

88.9%

无攻击第 60 轮准确率。

FedAvg 90.1%

Source: 实验汇总与配对比较

Tables:
logs\label_flip_continuous_iid\comparison_runs.csv,
logs\label_flip_continuous_iid\rounds*.csv

RTC 恶意权重

0.1%

All-reverse 第 11–60 轮恶意聚合权重。

FedAvg 20.2%

Source: 逐轮服务器与聚合指标

Table:
logs\label_flip_continuous_iid\rounds*.csv

RTC 阻断了全标签反转，但末轮 FedAvg 单点高度易波动

All-reverse 占主动期总训练暴露 20.20%。FedAvg 第 55、58、60 轮均抽中 3 名攻击者，准确率分别跌至 52.31%、64.76% 和 36.42%；第 59 轮只抽中 1 名时回到 89.77%。RTC 从第 11 轮即 restricted、第 12 轮出现 quarantine，主动期 96.0% 的恶意参与观测被隔离，恶意权重均值仅 0.08%。

第 60 轮 +51.21 个百分点是真实安全效果，但更稳健的主读数是主动期平均 +5.17 个百分点，以及对自身 clean 仅 -0.48 个百分点。


Source: 逐轮服务器与聚合指标

Table: logs\label_flip_continuous_iid\rounds*.csv

Clean 与 all-reverse 服务器准确率

Source: 逐轮服务器与聚合指标

Table: logs\label_flip_continuous_iid\rounds*.csv



RTC 没有压制定向 5→3 攻击

Targeted 主动期全局投毒暴露率 2.03%，eligible 样本投毒率 100%。第 10 轮攻击前 ASR 为 14.1%（FedAvg）和 15.0%（RTC），第 11 轮升到 48.8% 与 49.0%。第 11–60 轮平均 ASR 为 34.89% 和 38.66%；RTC 的 ASR-AUC 高 1.93，源类召回均值更低（46.48% 对 52.95%）。

第 60 轮 RTC ASR 44.1% 低于 FedAvg 的 53.8%，但该轮抽中 3 名攻击者，是高波动单点，不能覆盖完整主动期整体更差的事实。


Source: 逐轮服务器与聚合指标

Table: logs\label_flip_continuous_iid\rounds*.csv

5→3 定向翻转 ASR

Source: 逐轮服务器与聚合指标

Table: logs\label_flip_continuous_iid\rounds*.csv



定向攻击下四信号分离方向全部反了


定向攻击者在 magnitude、direction、frequency-temporal、influence 和 total risk 上的均值都低于良性客户端。恶意 total risk 0.449，良性 0.477；恶意平均 trust 更高（0.570 对 0.544），逐轮 trust AUC 仅 0.382。

RTC 主动期只把恶意权重从 20.20% 降到 17.77%，恶意单次平均聚合权重 8.79% 高于良性的 7.64%；恶意 quarantine 率 11.88%，反而低于良性的 22.06%。这不是单纯调低阈值能解决的问题。

Source: RTC 客户端级风险与状态
Table: logs\label_flip_continuous_iid\raw*rtc_full*_clients.csv

5→3 定向翻转的客户端风险均值

Source: RTC 客户端级风险与状态
Table: logs\label_flip_continuous_iid\raw*rtc_full*_clients.csv



干净代价来自激进裁剪与次概率质量损失

Clean RTC 在第 11–60 轮平均裁剪 50.0% 的参与观测、隔离 17.4% 的良性观测，聚合权重和仅 77.38%，即平均保留 22.62% 零更新质量；最终准确率低 1.15 个百分点。

All-reverse 下主动期零更新质量 40.05%，末轮 63.997%；良性 quarantine 主动期 22.60%，末轮 57.14%。更长训练或 Non-IID 下，有效客户端持续流失可能成为瓶颈。

Source: RTC 客户端级风险与状态
Table: logs\label_flip_continuous_iid\raw*rtc_full*_clients.csv

六组运行的主动期与最终指标

Source: 实验汇总与配对比较
Tables: logs\label_flip_continuous_iid\comparison_runs.csv, logs\label_flip_continuous_iid\rounds*.csv

#	Scenario	Defense	Active accuracy	Final accuracy	Active ASR	Malicious weight	Benign quarantine	Zero-update mass	Aggregat
1	5→3 targeted	FedAvg	84.4%	86.2%	34.9%	20.2%	0%	—	
2	5→3 targeted	RTC	82.5%	85.7%	38.7%	17.8%	22%	21.3%	
3	All-reverse	FedAvg	78.8%	36.4%	—	20.2%	0%	—	
4	All-reverse	RTC	84%	87.6%	—	0.1%	22.6%	40%	
5	Clean	FedAvg	86%	90.1%	—	0%	0%	—	
6	Clean	RTC	84.4%	88.9%	—	0%	17.4%	22.6%	

范围、设计与指标口径

- CIFAR-10, ResNet-18, 无预训练；20 客户端、每轮 10 个、IID、5 本地 epoch、batch 32、SGD、seed 42。
- 攻击第 11–60 轮连续生效；20% 恶意客户端；六组使用同一数据清单和客户端抽样计划。
- Targeted 为 Dog 5→Cat 3；all-reverse 为 $y'=9-y$ ；两者均对 eligible 样本 100% 翻转。
- Active accuracy/ASR 是第 11–60 轮算术平均；ASR-AUC 是该区间逐轮 ASR 的梯形积分。

- comparison_runs.csv 的 malicious_aggregation_weight_share 混入前 10 个无攻击轮；本报告的攻击期权重新按第 11–60 轮计算。

Source: 实验配置清单

Tables: logs\label_flip_continuous_iid\experiment_manifest.json, logs\label_flip_continuous_iid\raw*_config.json

可审计性、限制与稳健性

6/6 规格完成，每组 61 行（0–60），核心指标有限，数据 manifest hash 一致，硬约束违反量均小于 1e–8，日志未发现 Ray 容量或错误 1450。

证据仍是**单 seed 描述性结果**。同防御的攻击与 clean 运行在第 1–10 轮并非逐值完全重合：targeted 的平均前置差为 FedAvg –0.75、RTC +1.20 个百分点，说明跨子进程仍有随机漂移。Clean 又未记录 5→3 ASR/混淆矩阵，无法计算同轮 clean ASR lift。定向攻击差异只有约 2 个百分点，正式结论前必须修复这两项。

Source: 执行完整性门禁

Table: logs\label_flip_continuous_iid\execution_validation.csv

执行与硬约束门禁

Source: 执行完整性门禁

Table: logs\label_flip_continuous_iid\execution_validation.csv

Gate	Passed	Observed	Required
critical_metrics_finite	true	True	all finite
data_manifest_hash_match	true	{42: 1}	one hash per seed
matrix_complete	true	6/6 run files	6/6
rounds_complete	true	True	rounds 1..60 (+ optional round 0)
rtc_exposure_budget_violation	true	0	<= 1e-8
rtc_subprobability_mass	true	1	<= 1 + 1e-8
rtc_weight_cap_violation	true	0	<= 1e-8
selected_partition_ids_match	true	True	true
short_long_schedules_match	true	True	true

建议的改进顺序

1. **先修评估与可复现性**。Clean 也记录混淆矩阵和任意 source→target ASR；固定初始权重、DataLoader shuffle 与客户端 RNG，使同防御前 10 轮逐值一致；扩展到 3–5 seeds。
2. **为 targeted 加入类别敏感证据**。在服务器小型可信集上计算每个更新对 source=5 loss、target=3 logit margin 或 class-conditional gradient 的边际变化。当前四个全局更新信号全部反向，降低统一阈值会先伤害良性客户端。
3. **校准 clean 约束**。clip_multiplier=1.0 使每轮约半数客户端被裁剪；联合搜索裁剪分位数/乘数、状态阈值和恢复规则，并以 benign quarantine、zero-update mass、clean accuracy drop 为护栏。
4. **分开报告检测与缓解**。All-reverse 证明高影响攻击可被硬约束阻断；targeted 证明检测器没有识别攻击者。分别报告 trust AUC、恶意权重、攻击指标和 clean utility。
5. **频域价值留给 periodic 消融**。连续 targeted 中恶意 temporal risk 仅 0.010，低于良性的 0.045；不应以 continuous 结果作为频域正证据。

后续应回答的问题

- 多 seed 下，all-reverse 的收益和 targeted 的 ASR 劣化是否稳定？
- Class-conditional influence 能否把 targeted trust AUC 提升到 0.7 以上且不增加 clean false positive？

- 将 clean 零更新质量从 22.6% 降到 10% 以下后, all-reverse 安全收益是否保留?
- Dirichlet $\alpha=0.3$ 下, 良性异质性会把 clean quarantine 推高到什么程度?